Planning Project DE: E-commerce Batch Pipeline

Oct 30, 2026 · @Bejo Subejo

Ringkasan

Project ini adalah batch pipeline yang ngolah sekitar 40 juta event e-commerce (view, cart, purchase) dari Kaggle jadi dashboard penjualan dan funnel di Power BI. Data diproses bertahap di Databricks pakai PySpark dan dbt, dan seluruh alurnya dijalankan otomatis oleh Airflow.

Yang mau ditunjukin ke recruiter:

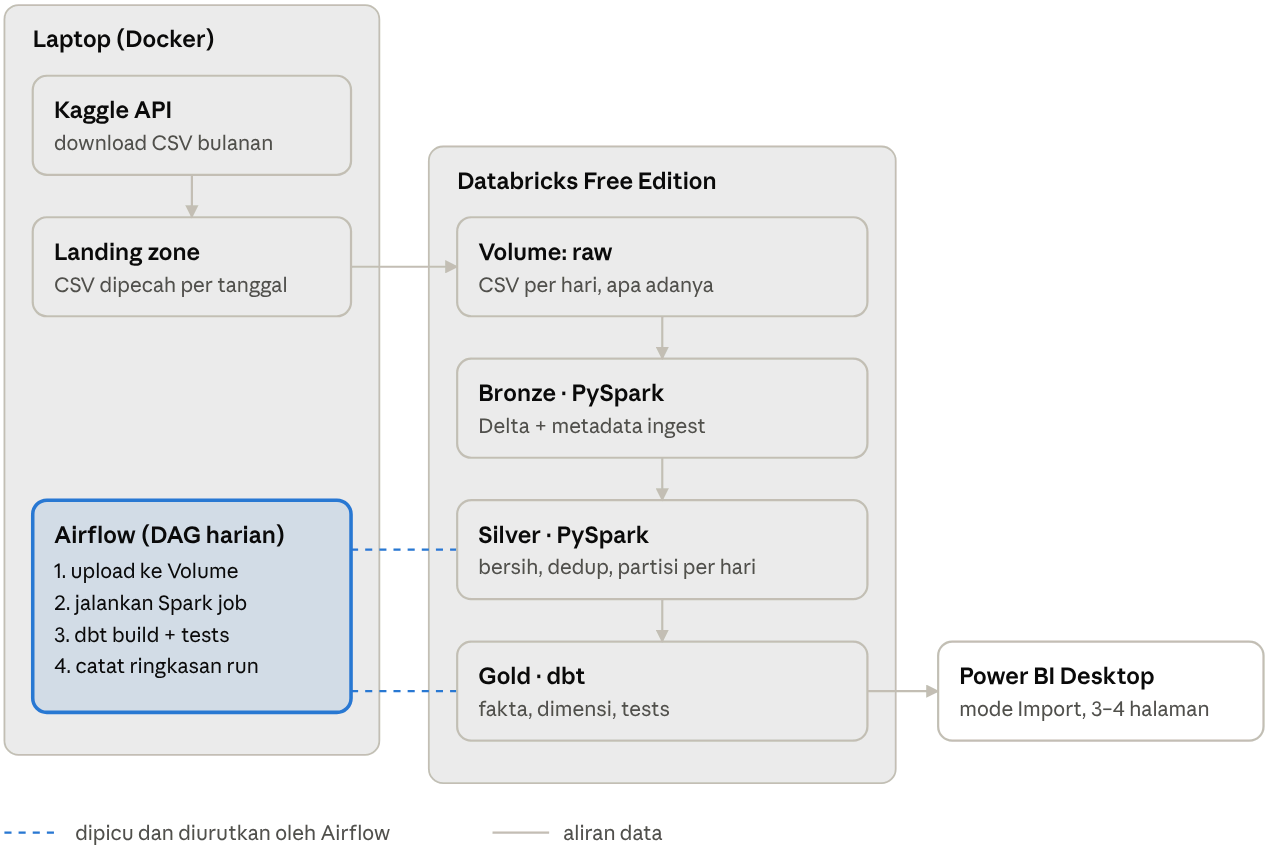
- Bisa ngolah data yang terlalu besar buat pandas pakai Spark, dengan alasan yang jelas.
- Paham pola **medallion** (bronze, silver, gold) dan format Delta Lake.
- Bisa bikin transformasi yang dites (dbt tests), bukan cuma "jalan di laptop gw".
- Bisa mengorkestrasi beberapa sistem berbeda (lokal, Databricks, dbt) dalam satu DAG Airflow.
- Pipeline-nya **idempotent**: dijalankan ulang untuk tanggal yang sama hasilnya tetap sama, nggak dobel.

Kafka sengaja di-hold. Ini murni project batch.

Arsitektur dan flow

Data mengalir dari Kaggle ke laptop, diupload ke Databricks, diolah bertahap sampai jadi tabel gold, lalu dibaca Power BI. Airflow di laptop yang menjalankan setiap tahap sesuai urutan, satu tanggal per run.

Airflow menggerakkan data dari laptop ke Databricks sampai Power BI



arsitektur pipeline · laptop, Databricks, Power BI

Spark dan dbt sama-sama berjalan di Databricks, bukan di laptop. Laptop cuma menyimpan file sementara dan menjalankan Airflow.

Tools

Semua tools di bawah gratis. Satu-satunya yang butuh Windows adalah Power BI Desktop.

Tool	Peran di project	Kenapa dipilih
Kaggle API	Download dataset	Bisa diotomasi, nggak perlu download manual
Databricks Free Edition	Tempat simpan data (Volume + Delta table) dan jalanin Spark	Gratis, nggak perlu setup cluster, nggak ada risiko tagihan
PySpark	Bronze ke silver: baca CSV besar, bersihin, dedup	Data 40 juta baris terlalu berat buat pandas

Tool	Peran di project	Kenapa dipilih
Delta Lake	Format semua tabel	Bisa overwrite per tanggal dengan aman dan ada time travel
dbt-core + dbt-databricks	Silver ke gold: tabel analisis + tests	SQL yang rapi, terdokumentasi, dan bisa dites
Airflow 3 (Docker, lokal)	Menjalankan semua tahap sesuai jadwal dan urutan	Standar industri buat orkestrasi
Power BI Desktop	Dashboard dari tabel gold	Banyak diminta di lowongan data di Indonesia
GitHub Actions	CI: lint Python + `dbt parse` tiap push	Nunjukin kebiasaan kerja yang rapi

Kenapa nggak ada database perantara (Postgres lokal, dll): data mentah itu file, jadi tempat paling pas buat nyimpennya adalah storage file. Masukin 40 juta baris ke Postgres dulu cuma nambah satu langkah yang lambat tanpa nilai tambah. Laptop jadi *landing zone* sementara, dan Databricks Volume jadi tempat data mentah yang "resmi".

Dataset

Pakai **eCommerce Behavior Data from Multi Category Store** di Kaggle (data REES46). File Oktober 2019 saja sudah sekitar 5 GB CSV dan kira-kira 42 juta baris, cukup buat MVP. Bulan November bisa ditambah di tahap lanjut. Angka ukuran ini perkiraan, cek ulang di halaman Kaggle-nya.

Kolom	Isi
`event_time`	Waktu kejadian (UTC)
`event_type`	`view`, `cart`, atau `purchase`
`product_id`, `category_id`	ID produk dan kategori
`category_code`	Kategori bertingkat, misal `electronics.smartphone` (sering kosong)
`brand`	Merek (sering kosong)
`price`	Harga

Kolom	Isi
`user_id`, `user_session`	ID user dan sesi

Masalah kualitas data yang perlu ditangani: `brand` dan `category_code` banyak yang kosong, ada baris duplikat, dan ada harga 0. Ini bagus buat portfolio, karena lo punya bahan cerita soal data cleaning.

Sebelum dipakai, cek lisensinya di halaman Kaggle dan cantumkan sumbernya di README.

Layer data

PySpark menangani pekerjaan berat (baca file besar, bersihin, dedup), dbt menangani logika bisnis yang dibaca dashboard. Pembagian ini juga jawaban bagus kalau interviewer nanya "kenapa pakai dua-duanya?".

Layer	Dikerjakan oleh	Tabel	Isi
Raw	Airflow (upload)	Volume `raw/events/date=YYYY-MM-DD/`	CSV per hari, apa adanya
Bronze	PySpark	`bronze.events`	Semua kolom asli + `_ingested_at`, `_source_file`
Silver	PySpark	`silver.events`	Tipe data benar, duplikat dibuang, harga 0 ditandai, `category_code` dipecah jadi `category_l1` dan `category_l2`, partisi per `event_date`
Gold	dbt	`dim_products`	Satu baris per produk: brand, kategori, harga terakhir
Gold	dbt	`fct_daily_sales`	Revenue, jumlah order, jumlah pembeli per hari

Layer	Dikerjakan oleh	Tabel	Isi
Gold	dbt	`fct_daily_funnel`	Jumlah sesi yang view, cart, purchase per hari + conversion rate
Gold	dbt	`fct_hourly_activity`	Event per jam dan hari dalam seminggu
Gold	dbt	`mart_top_products`	Produk dan brand terlaris per minggu

Aturan supaya idempotent:

- Bronze dan silver ditulis per tanggal pakai Delta `replaceWhere event_date = '<tanggal>'`. Run ulang untuk tanggal yang sama cuma mengganti partisi itu.
- Model fakta di dbt pakai materialization `incremental` dengan strategi `insert_overwrite` atau `merge` per tanggal.

dbt tests minimal:

- `not_null` dan `unique` di kunci tiap tabel gold.
- `accepted_values` untuk `event_type` (view, cart, purchase).
- `relationships` dari fakta ke `dim_products`.
- Satu custom test: revenue harian nggak boleh negatif.

DAG Airflow

DAG `ecommerce_daily` jalan sekali per hari data, dan tiap run hanya memproses satu tanggal. Dataset Kaggle-nya data historis, jadi kedatangan data harian disimulasikan: `start_date` 2019-10-01, `end_date` 2019-10-31, `schedule="@daily"`, lalu dijalankan sebagai backfill. Hasilnya Airflow memproses 31 hari secara berurutan, persis kayak pipeline yang sudah berjalan sebulan.

Persiapan sekali jalan (di luar DAG): script `scripts/split_by_day.py` membaca CSV bulanan per potongan (pandas `chunksize`) lalu menulis satu file per tanggal ke `data/landing/date=YYYY-MM-DD/`.

Urutan task per run:

1. `check_landing_file`: pastikan file tanggal itu ada. Kalau nggak ada, gagal dengan pesan jelas.
2. `upload_to_volume`: upload file ke Databricks Volume `raw/events/date=<tanggal>/` pakai Databricks SDK (`WorkspaceClient().files.upload`).
3. `run_spark_job`: `DatabricksRunNowOperator` menjalankan Databricks Job berisi dua task notebook PySpark (raw ke bronze, bronze ke silver), dengan parameter `run_date`.
4. `dbt_build`: `BashOperator` menjalankan `dbt build --vars '{run_date: <tanggal>}'` dari container Airflow ke SQL warehouse Databricks. `build` = run model + jalanin tests sekaligus.
5. `log_run_summary`: catat jumlah baris per layer ke tabel `ops.pipeline_runs`. Ini bahan buat bukti di README bahwa pipeline-nya benar-benar jalan.

Setting penting:

- `max_active_runs=1`, karena Free Edition cuma punya satu SQL warehouse kecil dan batas 5 task Job berjalan bersamaan.
- `retries=2` dengan jeda 5 menit untuk task yang memanggil Databricks.
- Kredensial (`DATABRICKS_HOST`, token) disimpan di Airflow Connection atau file `.env` yang masuk `.gitignore`. Jangan pernah di-commit.

Dashboard Power BI

Power BI Desktop terhubung ke SQL warehouse Databricks (konektor Azure Databricks / Databricks bawaan Power BI) dan membaca tabel gold saja. Pakai mode **Import**, bukan DirectQuery: data disalin sekali ke file Power BI, jadi klik-klik di dashboard nggak terus-menerus membangunkan warehouse dan menghabiskan kuota Free Edition.

Halaman	Isi	Sumber tabel
Overview	Kartu KPI: revenue, jumlah order, jumlah pembeli, conversion rate; tren revenue harian	`fct_daily_sales`, `fct_daily_funnel`
Funnel	View ke cart ke purchase per hari, drop-off antar tahap	`fct_daily_funnel`
Produk & brand	Top 10 produk dan brand, revenue per kategori, slicer kategori	`mart_top_products`, `dim_products`

Halaman	Isi	Sumber tabel
Pola waktu	Heatmap aktivitas jam x hari dalam seminggu	`fct_hourly_activity`

Untuk target 7 hari, tiga halaman pertama wajib. Halaman Pola waktu dikerjakan kalau masih ada waktu di hari 6.

Buat portfolio, berbagi dashboard di Power BI Service biasanya butuh akun kerja/sekolah. Jalan amannya: simpan file `.pbix` di repo, ekspor ke PDF, dan taruh screenshot tiap halaman di README.

Struktur repo

Satu repo untuk semuanya, dipisah per komponen supaya reviewer bisa langsung nemu bagian yang mau dilihat.

```
ecommerce-de-pipeline/
├── airflow/
│   ├── dags/ecommerce_daily.py
│   ├── docker-compose.yaml
│   └── requirements.txt        # provider databricks, dbt-databricks,
databricks-sdk
├── databricks/
│   ├── notebooks/
│   │   ├── 01_raw_to_bronze.py
│   │   └── 02_bronze_to_silver.py
│   └── job.json                # definisi Databricks Job
├── dbt/
│   ├── models/
│   │   ├── staging/            # stg_events (view di atas silver)
│   │   └── marts/              # dim_products, fct_*, mart_*
│   ├── tests/
│   └── dbt_project.yml         # profiles.yml baca dari env var, tidak di-
commit
├── scripts/
│   ├── download_dataset.sh     # Kaggle API
│   └── split_by_day.py
├── dashboard/
│   ├── ecommerce.pbix
│   └── screenshots/
```

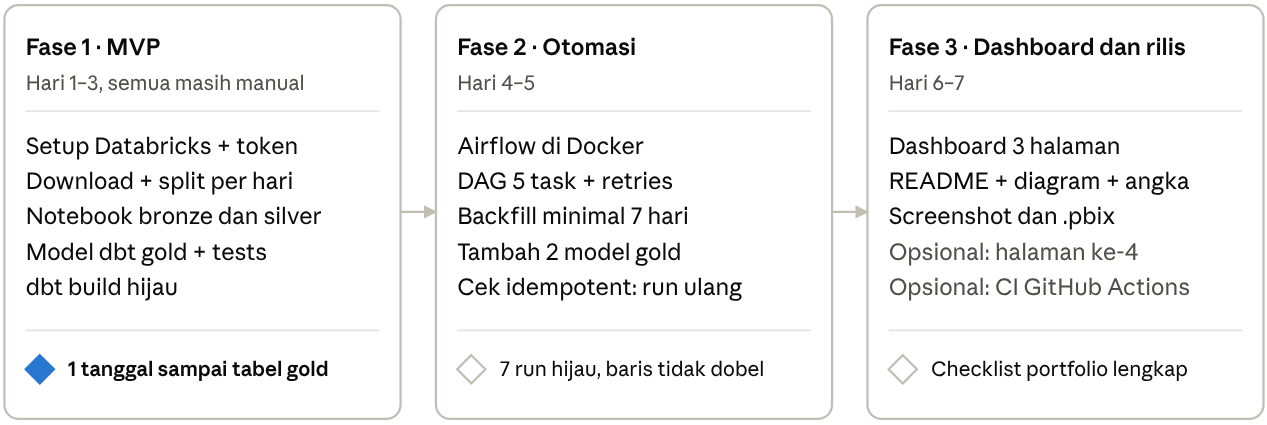
```
├── docs/architecture.png
├── .github/workflows/ci.yml
├── .env.example
└── README.md
```

Folder `data/` (file CSV) masuk `.gitignore`. Data sebesar ini nggak boleh masuk Git.

Timeline

Target 7 hari, dengan MVP di akhir hari 3: satu tanggal data jalan dari CSV sampai tabel gold, walaupun masih manual. Ini realistis kalau lo kerja sekitar 6–8 jam per hari dan scope dipangkas sedikit (lihat "Yang dipangkas" di bawah).

MVP selesai di hari 3, otomasi dan dashboard menyusul



rencana 7 hari · 3 fase, 3 gate

Jangan masuk ke fase berikutnya sebelum gate (tanda belah ketupat) fase sebelumnya tercapai. Airflow sengaja ditaruh setelah MVP: lebih gampang mengotomasi langkah yang sudah terbukti jalan manual.

Hari 1 · Setup dan data masuk

- [ ] Daftar Databricks Free Edition, buat catalog/schema dan Volume `raw`, generate token
- [ ] Download dataset Oktober pakai Kaggle API
- [ ] Jalankan `split_by_day.py`, upload 1 file tanggal ke Volume secara manual

Hari 2 · PySpark bronze dan silver

- [ ] Notebook `01_raw_to_bronze` dan `02_bronze_to_silver` jalan untuk 1 tanggal
- [ ] Catat masalah kualitas data (null, duplikat, harga 0) beserta jumlahnya

- [ ] Bungkus dua notebook jadi Databricks Job dengan parameter `run_date`

Hari 3 · dbt gold (gate MVP)

- [ ] Setup dbt-databricks ke SQL warehouse
- [ ] Model `stg_events`, `dim_products`, `fct_daily_sales`, `fct_daily_funnel` + tests
- [ ] `dbt build` hijau untuk 1 tanggal

Hari 4 · Airflow

- [ ] Airflow di Docker jalan, Connection Databricks terpasang
- [ ] DAG `ecommerce_daily` dengan 5 task, berhasil untuk 1 tanggal

Hari 5 · Backfill dan sisa model

- [ ] Backfill 7 hari; lanjut sampai 31 hari kalau kuota masih ada
- [ ] Run ulang satu tanggal, buktikan jumlah baris tidak dobel
- [ ] Tambah `fct_hourly_activity` dan `mart_top_products`

Hari 6 · Power BI

- [ ] Halaman Overview, Funnel, Produk & brand
- [ ] Halaman Pola waktu kalau sempat

Hari 7 · Rilis

- [ ] README: diagram, cara menjalankan, alasan tools, tabel sebelum vs sesudah
- [ ] Screenshot Airflow, dbt lineage, dashboard; commit `.pbix`
- [ ] Sisa waktu: CI GitHub Actions sederhana

Yang dipangkas dari rencana awal: data November dihapus dari scope, backfill minimal 7 hari (31 hari jadi bonus), halaman Pola waktu dan CI jadi opsional.

Risiko terbesar buat target 7 hari adalah setup Airflow di Docker dan koneksi dbt ke Databricks, karena dua-duanya sering makan waktu buat debug konfigurasi. Kalau hari 4 molor, hari 7 jadi buffer, dan CI yang dikorbankan duluan.

Batasan dan risiko

Risiko terbesar ada di batasan Databricks Free Edition, jadi desainnya dibuat hemat sejak awal.

Risiko	Dampak	Cara ngatasin
Akses internet keluar dari Databricks dibatasi ke domain tertentu	Notebook nggak bisa download dari Kaggle langsung	Download di laptop, lalu upload ke Volume lewat Airflow (sudah jadi desain utama)
Kuota compute harian; kalau lewat, compute mati sampai hari berikutnya	Backfill 31 hari bisa kepotong di tengah	`max_active_runs=1`, mulai dari 7 hari dulu; pipeline idempotent jadi tinggal lanjut besoknya
Cuma satu SQL warehouse ukuran 2X-Small	dbt dan Power BI rebutan, query lambat	dbt jalan berurutan, Power BI pakai mode Import
Hanya Python dan SQL (R dan Scala tidak didukung)	Nggak berpengaruh	Project ini memang pakai PySpark
Akun yang lama nggak aktif bisa dihapus	Kode dan tabel hilang	Semua kode di GitHub; tabel bisa dibangun ulang dari backfill
Personal access token bocor	Orang lain bisa akses workspace	Simpan di `.env` atau Airflow Connection, kasih masa berlaku, jangan commit
Airflow + Docker berat di laptop	Laptop ngos-ngosan	Pakai executor sederhana (LocalExecutor), Spark-nya sendiri jalan di Databricks, bukan di laptop
Power BI Desktop cuma ada di Windows	Kalau laptop lo Linux, nggak bisa buka	Pakai mesin Windows / VM, atau ganti ke Databricks AI/BI dashboard sebagai cadangan

Sumber batasan Free Edition: Databricks Free Edition limitations.

Checklist portfolio

Project dianggap selesai kalau semua poin ini ada di repo.

- [ ] README dengan diagram arsitektur, cara menjalankan, dan alasan pemilihan tools
- [ ] Screenshot Airflow: backfill minimal 7 hari, semua run hijau
- [ ] Screenshot dbt docs (lineage graph dari silver ke gold)

- [ ] Screenshot tiap halaman dashboard Power BI + file `.pbix`
- [ ] Tabel "sebelum vs sesudah": ukuran CSV vs Delta/Parquet, jumlah baris sebelum dan sesudah dedup
- [ ] Bukti idempotent: run ulang satu tanggal, jumlah baris tetap sama
- [ ] Daftar masalah kualitas data yang ditemukan dan cara menanganinya
- [ ] CI GitHub Actions hijau
- [ ] Bagian "Kalau dikembangkan lagi": streaming dengan Kafka, data November, alerting

Angka-angka di tabel "sebelum vs sesudah" dan cerita data cleaning adalah bahan paling kuat buat interview. Tulis angkanya dari hasil run lo sendiri.